# Chedy Korbi

Élève ingénieur IA/ML | LLM, RAG, vision par ordinateur, deep learning
Tunis | +216 58 239 045 | chedykorbi2021@gmail.com | linkedin.com/in/chedy-korbi | github.com/ChedyKorbi

## Profil

Élève ingénieur en Big Data & IA qui conçoit des systèmes de machine learning de bout en bout : pipelines de données, entraînement, évaluation rigoureuse et déploiement derrière des API. Pratique des LLM, du RAG, de la vision par ordinateur et du deep learning, sur un solide socle logiciel. Vise un poste en IA/ML, LLM ou vision.

## Expérience professionnelle

**Stagiaire ingénieur IA & mobile** juil. 2026 – août 2026
*SPIRAW by Food4Future* *Tunis, Tunisie*

- Étude : 23 040 photos de biomasse peuvent-elles remplacer le dosage de C-phycocyanine ? Splits par lot sans fuite
- MobileNetV2 entraîné sous PyTorch : $R^2$ 0,96 en test, 0,87 en leave-one-batch-out, devant CatBoost et XGBoost
- Explicabilité SHAP et Grad-CAM, tests de robustesse optique et démo Flask pour un futur capteur optique
- Refonte de l'assistant EERA : routage d'intention hybride (règles, correspondance floue, LLM en dernier recours) et garde-fous qui n'inventent jamais de mesure ni de prix ; précision de routage d'environ 75% à environ 100%
- Sécurisation de l'app Flutter : backend authentifié à la place du MQTT direct, boutique Stripe

**Stagiaire de fin d'études, IoT & IA/ML** janv. 2025 – juin 2025
*Symatique Software* *Tunis, Tunisie*

- Modèles scikit-learn calibrés par race et âge qui signalent les risques de santé à partir de capteurs portés
- Flux ESP32 via MQTT vers les services d'inférence, 50+ utilisateurs simultanés, latence inférieure à la seconde
- Alertes livrées dans une app Android, un portail vétérinaire Angular et un chatbot NLP Rasa

**Stagiaire développeur IA & mobile** juil. 2024 – août 2024
*Sagemcom Software & Technologies, R&D* *Tunis, Tunisie*

- Intégration d'un modèle EfficientNet embarqué (TensorFlow Lite) pour reconnaître les produits en temps réel
- Identification de 30 s à moins de 5 s et erreurs de saisie manuelle réduites de 80%

## Projets IA

**GroundedDocs** | *Python, FastAPI, Qdrant, LangChain, Groq, Docker, GitHub Actions*

- API RAG sur documents d'entreprise qui cite chaque affirmation et refuse de répondre sans preuve
- Fusion dense + BM25 (RRF) et reranking cross-encoder : Recall@3 de 88,9% à 100%
- Vérification de chaque affirmation : 96,3% de fidélité, 88,2% de citations exactes sur 48 questions de référence
- Authentification par clé, limitation de débit, suivi de latence et de coût, Docker, CI et 113 tests

**CourtVision** | *PyTorch, YOLO11, BoT-SORT, SmolVLM2, OpenCV, TensorRT, FastAPI*

- Pipeline qui transforme une vidéo NBA en joueurs suivis avec équipe, numéro et position sur le terrain
- YOLO11 fine-tuné (28 843 boîtes) ; suivi BoT-SORT + ré-ID : HOTA 0,602 contre 0,393 pour ByteTrack
- Projection terrain via points clés et homographie RANSAC : erreur médiane 0,695 ft ; 398/420 équipes justes
- Lecture des numéros de maillot en zero-shot par modèle vision-langage (SmolVLM2), précision 99%

**BurgerVision** | *RF-DETR, YOLOv8, ONNX Runtime, OpenCV, FastAPI*

- Caméra temps réel, hors ligne, qui vérifie chaque burger d'un client de restauration rapide face à sa recette
- Comparaison RF-DETR, YOLOv8, D-FINE ; confirmation multi-images, filtre qualité, règles de recette
- mAP50 sur cuisines client inédites porté de 0,45 à 0,77, et 0,889 sur la station d'origine
- 26/28 verdicts justes sur vidéos de test (modèle du client : 21/28), zéro faux « conforme »

**AERIS** | *Python, PyTorch, Audio Spectrogram Transformer, Spring Boot, Next.js*

- Prototype de recherche en IA clinique qui réunit radio thoracique, sons pulmonaires, notes et constantes
- Modèle de risque cardiaque à 0,89 d'AUROC sur données verrouillées ; transformer audio en entraînement
- Chaque sortie IA exige la validation d'un clinicien, et la sortie d'origine est conservée pour l'audit

**FinSight AI** | *scikit-learn, XGBoost, LightGBM, statsmodels, FastAPI, Spring Boot*

- Responsable ML d'une plateforme fintech : six modèles calibrés (fraude, anomalies, crédit, prévision)

- Fraude : XGBoost, calibration isotonique et seuil sensible au coût, PR-AUC 0,866 sur le benchmark ULB
- Scorecard crédit avec motifs exacts à 0,81 d'AUC ; prévisions de trésorerie 27% meilleures (WAPE)

**RaceDeck F1 AI** | *Python, FastF1, scikit-learn, MLflow, FastAPI, Docker*

- Plateforme MLOps : briefings F1 d'avant-course (rythme, simulation, stratégie pneus) à partir des tours
- Modèle de rythme corrigé du carburant et de la piste : erreur 1,33 s contre 11,31 s, validé sur 11 Grands Prix
- Simulateur Monte-Carlo de 4 000 courses suivi dans MLflow ; un modèle n'est livré que s'il bat sa baseline

## Formation

**Cycle ingénieur, Big Data & Intelligence Artificielle** sept. 2025 – en cours
*Polytech International* *Tunis, Tunisie*

**Licence, Systèmes embarqués & développement mobile** 2022 – 2025
*ISET Charguia, moyenne 16,78/20* *Tunis, Tunisie*

## Compétences techniques

**Deep learning & vision :** PyTorch, TensorFlow, YOLO, OpenCV, ONNX Runtime, TensorRT, Grad-CAM
**Machine learning :** scikit-learn, XGBoost, LightGBM, CatBoost, statsmodels, SHAP, séries temporelles, NLP
**LLM & RAG :** LangChain, LangGraph, Qdrant, FAISS, Groq, prompt engineering, évaluation de LLM
**MLOps & données :** Python, SQL, pandas, NumPy, FastAPI, Docker, MLflow, GitHub Actions, pytest
**Logiciel :** Java, TypeScript, C/C++, Spring Boot, Django, Next.js, Angular, Flutter, Android, ESP32, MQTT

## Certifications

**Samsung Innovation Campus, IA :** projet final multimodal (EfficientNetB3, BERT, LLM), 95,5%, 4e place
**AWS AI Practitioner Challenge** (Udacity) : LLM, RAG et IA agentique
**IT Specialist, Big Data** (Certiport)

## Langues

Arabe (langue maternelle), français (professionnel), anglais (professionnel)